

# 工程实训

---

计算机学院 · 计算机科学与技术

授课教师：张金区

2026 年 9 月 23 日

# 课程简介

- 计算机工程实训的主要目的是将理论知识与实践操作相结合，提升动手操作能力和解决问题的能力。通过工程实训，尝试在模拟或真实的项目环境中，应用所学的计算机工程知识，从而加深理解并掌握实际操作技能。此外，通过实训了解团队协作、创新思维以及应对挑战的能力。

# 1. 计算机工程的概念

- 计算机工程是指应用计算机科学、数学和通信技术来设计、开发、实施和维护信息系统的一系列活动。这些系统能够收集、存储、处理、传输和展示数据，从而支持组织的运营和决策过程。

## 2. 计算机工程涉及的关键技术领域

- 软件开发：编写和维护应用程序以满足特定业务需求。
- 数据库管理：设计和管理数据库系统以高效存储和检索数据。
- 网络通信：构建和维护计算机网络以实现数据传输和资源共享。
- 信息安全：保护数据和系统免受未经授权的访问和攻击。
- 人工智能与机器学习：应用智能算法来模拟人类决策和学习过程。

### 3. 计算机工程应用范围

- 计算机信息工程广泛应用于各个行业，包括但不限于：
- 制造业
- 服务业
- 医疗保健
- 教育行业
- 政府部门
- 金融服务业
- .....

# 4. 实施阶段或步骤

- 1. 项目启动
  - 项目立项：正式批准项目并分配必要的资源。
  - 组建项目团队：确定项目经理和关键成员。
  - 制定项目章程：明确项目目标、范围、预算和时间表。
- 2. 需求分析与规划
  - 需求调研：收集和分析用户及利益相关者的需求。
  - 业务流程优化：重新设计或改进现有工作流程。
  - 制定详细项目计划：包括各阶段的目标、任务分配和里程碑。
- 3. 技术选型与架构设计
  - 技术评估：选择最适合项目需求的技术栈和工具。
  - 系统架构设计：构建系统的整体框架和模块划分。
  - 数据库设计：规划数据的存储、访问和管理方式。

- 4. 软硬件采购与开发

- 采购招标：选购所需的硬件设备和软件许可。
- 软件开发：编写代码或定制应用系统。
- 接口设计与集成：确保不同系统间的兼容性和数据流通。

- 5. 基础设施建设

- 物理环境建设：建立数据中心和网络基础设施。
- 系统安装与配置：部署服务器、网络设备和安全设施。

- 6. 系统测试

- 单元测试：验证单个组件的功能正确性。
- 集成测试：检查各部分协同工作的性能和稳定性。
- 用户验收测试（UAT）：确保系统满足业务需求和用户期望。

- 7. 培训与部署

- 用户培训：对最终用户和相关人员进行操作培训。
- 数据迁移：将旧系统的数据安全迁移至新系统。
- 上线部署：正式将系统切换到生产环境并启动运行。

- 8. 运维支持

- 技术支持：提供持续的技术援助和故障排除服务。
- 维护更新：定期对系统进行维护和必要的升级。
- 性能监控：实时监控系统的运行状态和性能指标。

- 9. 项目评估与验收

- 文档归档：整理和保存所有相关的项目文件和资料。
- 项目验收：组织专家组进行验收汇报和演示。
- 项目交接：将项目的所有权和管理权移交给运维团队或相关部门。

风险提示 | gpcgd.gd.gov.cn

政府采购

GPCGD

广东省政府采购中心

Government Procurement Center of Guangdong

信息无障碍

优质 · 高效 · 专业 · 廉洁

首页

信息公开

要闻动态

办事服务

公众互动

重要政策举措及实施效果

加大宏观政策调控力度

着力扩大内需

加快建设现代化产业体系

进一步深化改革扩大开放

保障和改善民生

点击查看专栏>>

| 通知公告                                |            |
|-------------------------------------|------------|
| 广东省政府采购中心2025年公开招聘编外合同制工作人员资格初审结... | 2025-10-09 |
| 2024年广东省政府采购中心网站年度工作报告              | 2025-01-02 |
| 关于召开计算机批量集中采购配置交流会议的通知              | 2025-10-11 |
| 关于签订广东省2025年度复印纸框架协议的通知             | 2025-10-10 |
| 关于邀请各复印机制造商参与批量集中采购答疑会的通知           | 2025-09-29 |
| 关于召开2026年第一期空调机批量集中采购会议的通知          | 2025-09-29 |

查询信息

关键字:

分类: 

所有

最近 

全部

发布的项目

Q

搜索

采购信息公告

中标、成交结果公告

广东省外语艺术职业学院校园安全管理中心项目招标公告

2025-10-11

省“一网统管”基础平台升级改造与运营（2025年）项目招标公告

2025-10-10

省经济态势感知研判平台升级及运营服务（2025年）项目招标公告

2025-10-10

## 5. 课程目标

- 旨在锻炼和提升三个方面的能力：问题发现能力、文档总结能力和工程实现能力。
- 同时，通过工程实训，了解当今计算机前沿技术发展的趋势，学习及训练前沿技术涉及的相关技术与算法，例如人工智能、大数据分析、深度学习算法及工具、VR/AR开发工具及开发方法、最新程序设计技术等，并针对具体问题完成相应需求撰写、系统或软件模块的开发，形成解决相关前沿工程实际问题的能力。

# AI 已经会写代码了，这门课还训练什么

评分不看你能不能写出来，看你能不能论证清楚

## AI 现在就能做

- 生成脚手架和样板代码
- 解释报错、给修复建议
- 生成测试用例草案
- 润色文档、初步梳理文献
- 调用任何现成的库和模型

## AI 替代不了 —— 也就是你的评分点

- 定义问题：解决谁的什么问题、凭什么说现在做得不好
- 方案权衡：为什么选它、放弃了什么、代价是什么
- 设计评测：基线是什么、指标怎么定、怎么算成功
- 核查 AI 的产出，并说明你改了些什么、为什么改
- 为最终交付负责

# 这门课做什么

用 **两万条真实的地学开放数据目录**，完整走一遍从「发现问题」到「交付一个别人能跑起来的系统」的工程流程。

1

## 真实数据

来自 11 个国际数据源、10 个主题领域。不是教学玩具数据集，是地学专家正在使用的数据。

2

## 真实问题

这批数据本身有大量缺陷。你不需要凭空想题目——缺陷就是题目，而且有客观对错。

3

## 真实评测

全班共建一套评测集，用同一把尺子量不同的方案。你的结论必须能被验证。

# 数据情况

129,388

条原始数据集记录  
已采集入库

11

个国际数据源  
DataONE / Zenodo / USGS /  
STAC ...

10

个学科领域  
卫星遥感 / 冰冻圈 / 海洋 / 地质 ...

20,000

条教学底座  
你实际使用的数据量

## 为什么要缩到两万条

12.9 万条里有 3.78 万条来自 Crossref——那是文献记录，不是数据集（其中 3.6 万条连描述都没有），已整源排除。剩下 9.16 万条里按学科配额抽出 2 万条：小的学科全收，大的按比例，同时保证每个数据源都有席位。全量数据保留在导师侧用于最终评测——所以你的方案不能只在两万条上好看。

# 数据长什么样：30 个字段

六组信息，覆盖一个数据集从「是什么」到「能不能用」的完整描述

## 1 标识

id · title · record\_id · doi

## 2 内容

description · keywords · data\_type

## 3 来源与溯源

source\_adapter · source\_paradigm ·  
source\_url  
providers · discovered\_at · search\_query  
· search\_topic

## 4 时空

spatial\_bbox · spatial\_crs  
temporal\_start · temporal\_end

## 5 访问与合规


distributions · license  
accessibility · last\_checked\_at

## 6 评分与排序

confidence · citation\_count · cnci\_score  
importance\_score · is\_core · is\_deleted

# 数据源构成：11 个采集适配器

每条记录都带着来源标记，这让你能做跨源对比和规范化




## 看出来的问题

- Crossref 已整源排除——它返回的是文献记录而不是数据集，3.78 万条里 3.6 万条没有描述
- PANGAEA、EMODnet 这类地学专业库只剩几十条，不是它们数据少，是采集适配器覆盖得浅
- 不同源用的是不同元数据规范（DCAT / CSW / STAC / DataONE），字段含义并不统一
- 数据源注册表里登记了 38 个源，真正采到数据的只有 11 个——采集链路的覆盖率本身就值得查

# 学科分布：10 个领域

大类很大、小类很小——这个失衡本身就是一道题



## 两头都是机会

### 大类（几千条）

适合做检索、分类、推荐——样本足、统计稳。

### 小类（几十到几百条）


古气候只有 77 条、土壤土地 415 条。这是真实的数据荒漠，值得做缺口分析。

### 样本量决定了你能做什么

几百条的类做不了需要训练的模型，但正好适合做质量审计和人工标注。

# 字段填充率：能靠的字段没几个

填充率决定哪些任务做得起来——空间范围只有 16.6%



## 这对你意味着什么

只有标题和数据类型的覆盖是可靠的。

做检索任务：描述和关键词的覆盖还算够用（78.9% / 60.0%），但要先处理缺失和 HTML 残留。

做空间检索：天然受限，只有 16.6% 带范围。你要么从描述里推断，要么承认并说明这个边界。

做合规分析：许可只有 31.6%，缺口极大。

做去重：577 组重复标题必须处理，否则所有统计都会重复计数。

# 这批数据的真实问题

全部来自实测，就是你手上这两万条

4,167

条描述残留 HTML 标签

3,896

条描述中含换行符

6,273

条描述被硬截断在 1000 字

8,009

条没有关键词

969

条时间起点晚于终点

1,419

条时间字段含未来日期

301

条空间范围越界或颠倒

577

组标题重复登记（同一数据集重复入库）

# 关键转变：问题就是题目

## 你不需要凭空想一个题目。

上一页那些缺陷，每一个都是一个真实的工程问题，而且都能造出客观金标来判断你做得对不对。

4,167 条 HTML 残留

→ **数据清洗流程**

2,388 条时间字段异常

→ **字段语义识别与规范化**

8,009 条关键词缺失

→ **自动标注与质量评估**

577 组标题重复登记

→ **跨仓库去重与合并**

# 你能做什么：四层任务

每层都有名额上限，避免全班挤在同一个题目上

|    |           |                   |    |
|----|-----------|-------------------|----|
| 01 | 数据质量审计与修复 | 清洗、校验、去重、语义规范化    | 入门 |
| 02 | 分类与标注质量改进 | 分类纠错、受控词表映射、关键词补全 | 核心 |
| 03 | 发现与检索     | 语义检索、跨语言检索、数据集推荐  | 核心 |
| 04 | 知识发现与智能体  | 资源态势分析、缺口识别、数据助手  | 挑战 |

# 第 01 层 | 数据质量审计与修复

入门

## 可以做的子问题

- 描述清洗：HTML 标签 4,167 条、换行 3,896 条
- 时间规范化：区分数据覆盖期与采集时刻
- 空间校验：修正 301 条越界或颠倒的 bbox
- 跨仓库去重：577 组重复标题怎么合并
- 缺失补全：8,009 条没有关键词

## 选题提示

问题边界清楚、对错可验证，适合想稳扎稳打的同学。

## 为什么值得做

把脏数据变成可用的数据。每个子问题都有客观金标，最容易评分。

## 交付物

清洗后的数据集 + 审计报告 + 可复现脚本

建议名额：不限

# 第 02 层 | 分类与标注质量改进

核心

## 可以做的子问题

- data\_type 分类纠错：软件手册、工业矿点被误判为「冰冻圈」
- 自由词 → GCMD 受控词表映射（STAC 用标准词表，其他源是自由词）
- 关键词自动补全：8,009 条为空
- 标注质量评估：怎么证明你的标注比原来准

## 选题提示

需要你自己造金标——标 300–500 条就足以支撑结论。

## 为什么值得做

现有字段的质量很差，改进它需要你既懂方法、又能证明改对了。

## 交付物

改进后的标注 + 人工金标对照 + 准确率/一致性分析

建议名额：3–4 队

# 第 03 层 | 发现与检索

核心

## 可以做的子问题

- 自然语言检索：「2010–2020 年青藏高原积雪深度观测」→ 相关数据集
- 跨语言检索：中文查询、英文元数据
- 从论文或研究计划推荐可用数据集
- 自建基线：数据包里没有索引，朴素关键词检索只是最弱的下限

## 选题提示

推荐给想做技术核心的人。评测集全班共享，但方案各写各的。

## 为什么值得做

这门课最有价值的一层。研究者找不到数据集，是真痛点，而且可评测。

## 交付物

检索系统 + 评测报告（含基线对比、错误分析）

建议名额：4–5 队

# 第 04 层 | 知识发现与智能体

## 挑战

### 可以做的子问题

- 地学数据可访问性态势分析：按主题、区域、机构看覆盖与缺口
- 数据荒漠识别：哪些方向真的缺数据（古气候只有 77 条）
- 地学数据助手：找数据 → 比数据 → 给引用建议
- 面向数据管理者的元数据质量工具
- 数据智能推荐
- 数据集重要性评估

### 选题提示

名额有限，需要先证明你能独立推进，再来选这一层。

### 为什么值得做

面向真实用户做产品。难度最高，也最可能做出能拿出去的东西。

### 交付物

可演示的产品 + 用户测试记录 + 结论文证

建议名额：2 队

# 数据包里没有索引：基线要你自己建

这不是遗漏，是任务的一部分

## 你手上有什么

- 2 万条结构化目录记录，30 个字段
- 一个朴素关键词检索可用 (`geodata.naive_search`)
- 完整的字段说明与不可信字段清单
- 没有索引、没有向量、没有排序模型

## 你要交出来的

- 一个能用的检索或推荐系统
- 和朴素基线在同一评测集上的对比
- 指标: Recall@k / nDCG / MRR
- 错误分析: 你的方案在哪类查询上失效、为什么
- 一份能让别人跑起来的 README

**记住这条判据：一个方案好不好，不取决于它本身多精巧，取决于你能不能说明它比现有做法好在哪里。说不出来的，就是没做完。**

# AI 使用规则

可以用，而且鼓励用 —— 但必须留下痕迹

## 交给 AI 做（省时间）

- 生成脚手架、样板代码
- 解释报错、查文档
- 生成测试用例草案
- 文档润色、术语统一
- 初步的文献梳理

## 必须你自己做（就是评分点）

- 定义问题和目标用户
- 技术选型与权衡说明
- 设计评测（基线、指标、成功标准）
- 核查并修改 AI 的每一条产出
- 判断依赖、风险与边界

## 必须提交《AI 使用记录》

用了什么工具 → 提了什么 → 拿到什么 → 你改了什么 → 为什么改。不提交，视为未声明使用，按违规处理。

# 你要交什么

1

## 系统与源码

Git 仓库，含 README，换台机器能跑起来

2

## 需求与设计文档

问题、用户、方案、权衡

3

## 评测报告

基线对比 + 指标 + 错误分析

4

## AI 使用记录

用了什么、改了什么、为什么改

5

## 综合实训报告

完整的项目文档


6

## 答辩PPT

现场演示 + 回答问题

# 时间节奏：三个必须交付的节点

不要拖到最后一周 —— 每个节点都计分



## 节点 1

### 立项答辩

3 分钟讲清：  
谁的什么问题  
怎么算成功

## 节点 2

### 设计与实现

设计说明与实施方案  
原型与架构  
技术选型理由

## 节点 3

### 验收与答辩

完整系统  
PPT报告  
AI 使用记录

另外两项：参与 3 位同学的立项评审。

# 课程考核与成绩评定标准

1. 参与度（30%），其中
  - 及时发布个人选题，10%
  - 及时对他人选题进行评价：10%
  - 及时提交工作报告，10%
2. 作品得分（70%）

# 作品评分标准

评的是「论证最扎实」，不是「指标最高」

## 20% 方案论证

为什么这么做、放弃了什么、代价是什么

## 20% 评测严谨性

有没有基线、指标选得对不对、做没做错误分析

## 15% 问题定义

解决谁的什么问题、凭什么说值得做

## 15% 可复现性

换台机器能否按 README 跑起来

## 15% 工程完整度

功能是否完整、代码是否规范

## 15% AI 使用规范

有没有如实记录、有没有核查痕迹

一条明确规则：说得清为什么这么做、可复现。

# 团队与分工

这门课允许团队合作，也可以独立完成。

## 组队规则

- 不多余 3 人一组
- 必须有明确的任务分工表
- 组长决定每人的贡献系数

**个人得分 = 小组作品分 × 个人贡献系数**

## 独立完成

完全自我掌控。

**个人得分 = 小组作品分**

# 你现在要做的第一步

1

**跑通数据上手包**

装好环境。

2

**浏览数据，找到你的问题**

对着四层任务挑一个方向，看看数据里到底有什么，也可以选找到的其他问题。

3

**提交选题**

写清楚：解决谁的什么问题、打算怎么做、怎么算成功。

4

**参与立项评审**

给 3 位同学的选题提意见。这也是计分的。



# 请大家按时间节点完成相关任务。

---

有问题随时找我 —— 数据跑不通、题目拿不准、方案想不清楚，都早说。

张金区 · 计算机学院